

3J

제 4회 BDAI 채용 연계 데이터 분석 공모전 2차 본선 발표

진선윤, 최재은, 정환희

목차

1

문제 정의

2

제안 배경 및 필요성

3

데이터 탐색 및 전처리

4

모델링 전략 설계

5

모델링 학습방식

6

모델 검증 및 과적합 점검

7

모델별 성능 비교

8

결론 및 기대효과


1 문제 정의

- 주제

- 스마트 팩토리 전력 소비 예측
데이터 분석 및 시각화

- 목표

- 공장 단위 1시간 평균 총 전력 사용량 예측



- 데이터 및 분석 관점

- 5초 주기 설비 단위 전력 데이터 활용
- 총 전력 변동을 설비 수준에서 해석

💡 핵심 문제 정의 💡



- 총 전력 변동은 시간적 패턴에 의한 것인가?
- 설비 조합 변화에 따른 순간 변동인가?
- 예측 오차가 큰 구간의 발생 원인은 무엇인가?

2

제안 배경 및 필요성

• 데이터 관찰

- 분산, 분위수 기준 → 장기간 드리프트 관찰 X
- 대부분 시간대에서 총 전력은 좁은 범위 내 분포
- 일부 시간대에서만 급격한 전력 변동 발생




• 문제 인식 및 접근 필요성

- 단순 시계열이 아닌 시간/설비 조합에 따른 구조적 변동 가능성
- 5초 설비 데이터를 1분/1시간 단위로 집계하여 탐색적 데이터 분석을 수행

3


데이터 탐색 및 전처리

< 집계 단위에 따른 전력 변동성 >



집계 단위 증가에 따라 전력 변동성 급격히 감소
(5초 단위, 1분 단위, 1시간 단위)


< 공장 TOTAL 전력 사용량의 1시간 단위 시계열 >



장기간 관측 결과, 전력 분포의 드리프트 없이
안정적인 시계열 구조 확인


3 데이터 탐색 및 전처리

< TOTAL 전력 변동 구간에서의 설비별 기여 분포 >



TOTAL 변동은 단일 설비가 아닌 다수 설비의
동시적 기여 누적으로 형성


< 캘린더 기반 기준선과 lag 기반 기준선 MAE 비교 >



전력 사용은 lag 기반 접근 대비
캘린더 기반 기준선이 평균 오차 측면에서 더 안정적

3 데이터 탐색 및 전처리


< 요일 x 시간대별 설비 전력 편차 분해 >



전력 변동은 요일 x 시간 패턴 위에서 발생


3 데이터 탐색 및 전처리

< 시간대 × 설비 평균 전력 Heatmap >



일부 설비에서 특정 시간대에 반복적으로
높은 전력 사용 패턴 확인

< 상위 5% 전력 사용 구간의 발생 시간 >




피크 전력은 특정 시간대에 집중되며,
단발성 이벤트보다 반복적 시간 패턴이 지배적

3 데이터 탐색 및 전처리

< 월간 전력 사용량 및 경제적 환경적 영향 분석 >

월간 전력 사용량 및 경제적·환경적 영향 분석



전력 사용량 증감은 비용 및 탄소배출에 거의 선형적으로 반영됨



전력 예측은 비용 절감과 ESG 의사결정으로 직접 연결

💡 EDA 결과 💡

→ 이 문제는

요일 x 시간 패턴 및 설비 기반 구조적 패턴

+ 이벤트 분리 전략이 적합

→ 이후 모델링은

캘린더 기반 기준선 구조 채택

4 모델링 전략 설계


모델링 접근 흐름

1. Calendar Baseline (Weekday × Hour)
→ 전체 전력 스케일은 캘린더 패턴이 지배
2. 잔차 보정 (Top-Down)
→ 시간 단위 미세 변동 보정 시도
3. 구조적 한계 확인
→ TOTAL 단일 시계열은 설비 조합 구조 반영 한계
4. 문제 재정의 (Bottom-Up)
→ 설비 단위 예측 후 합산으로 구조 반영

전략 1 : Calendar Baseline (Weekday × Hour)

- 월 누적 전력 오차 $\approx 0\%$
- 시간 단위 MAE ≈ 82
- 전체 스케일은 캘린더가 지배
- 미세 변동은 잔차로 남음

< 요일 × 시간 기반 공장 TOTAL 전력 사용량 평균 패턴 >




전략 2 : Baseline + LightGBM Residual

- Calendar Baseline이 놓친 시간별 잔차를 ML로 보정
- LightGBM: MAE $\approx$ 70
- 비선형 보정은 유효하지만, 재귀 예측/누적 안정성 trade-off 발생 가능
- “잔차 보정은 된다”를 확인 → 더 안정적인 보정 방식 탐색 필요

전략 3 : Baseline + Ridge

- Ridge: 가장 안정적인 개선
- MAE $\approx$ 24.66
- 잔차는 복잡하지 않음
- 선형 보정이 오히려 효과적

<각 전략별 오차 분포>



전략1(S1) MAE : 82.20

전략2(S2) MAE : 70.28

전략3(S3) MAE : 24.66

5 모델링 학습방식

Top-Down 방식의 한계

- TOTAL을 단일 시계열로 취급 → 설비 조합 구조 직접 학습 어려움
- 설비 조합 구조 반영 한계 → 피크/변동은 여러 설비의 미세 편차가 누적되어 발생



Bottom-Up 설비 단위 모델

구조

- 설비(module) × 시간(hour) 단위 예측
- 동일 시각 설비 예측값 합산 → TOTAL


장점

- EDA에서 확인한 데이터 생성 구조와 일치
- 이벤트/잡음의 분산 효과

전략 4 : Bottom-Up Module Modeling

- $TOTAL = \sum \text{module}$
- 모듈별 예측 오차가 합산 과정에서 상쇄 $\rightarrow$ TOTAL 기준 오차 감소

< Module-level MAE Distribution >



5


모델링 학습방식

전략 4 : Bottom-Up Module Modeling

< 결과 >

Module MAE 2.56 / Total MAE 1.74


Top-Down 대비 모든 지표(MAE/RMSE/SMAPE) 개선



6 모델 검증 및 과적합 점검

최종 모델 신뢰성 검증

- ① Target Shuffled Test
Target 무작위 섞기 → 성능 붕괴
(MAE : 1.74 → 80.49) → Leakage 없음
- ② Module Shuffled Test
Module 순서 변경 → TOTAL 성능 유지
(MAE : 1.74 → 1.75) → 설비 ID 과적합 아님



**최종 모델로 Bottom-Up
LGBM 채택**



결론

- 성능은 특정 변수 암기X
- 과적합 없이 일반화 가능한 모델로 판단

7 모델별 성능 비교

모델명	접근 방식	MAE ↓	RMSE ↓	SMAPE ↓
Calendar Baseline	Top-Down	82.20	102.01	0.210%
Baseline + LightGBM Residual	Top-Down	70.28	89.81	0.180%
Baseline + Ridge	Top-Down	24.66	30.60	0.063%
Bottom-Up Module Modeling	Bottom-Up	1.74	0.3651	0.0003%

8 결론 및 기대효과



2025년 5월(예측, 빗금친 부분)

- **예상 전력 사용량**: 약 2,629만 kWh로 감소
- **예상 탄소 배출량**: 약 11,148톤으로 피크 구간 대비 완화되는 추세
- **예상 전기요금**: 약 47.3억 원으로 과거 최대 비용 월 대비 운영 비용 절감 가능성

➡ 비용 절감과 환경 부담 완화를 동시에 달성할 수 있는 운영 판단 근거로 활용

8 결론 및 기대효과

기대효과

- TOTAL 예측 정확도 및 안정성 동시 확보
- 설비 단위 확장 가능한 구조적 모델링 프레임워크
- 유사 제조 및 에너지 데이터 문제에 일반화 가능

한계점

- 과거 데이터 기반 학습 구조 → 설비 구성 변경이나 신규 설비 추가 시 재학습이 필요
- 예기치 못한 비정상 운전 이벤트에 대한 직접적인 대응에는 한계 존재

- ▶ 향후 실시간 이상 탐지 모델과의 결합 or 운영 스케줄 정보의 추가 반영
→ 예측의 실효성과 활용 범위를 더욱 확장 가능성

감사합니다.

Q&A

3J: 진선윤, 최재은, 정환희